

W03

Fekete Máté

2020 Április

Tartalom jegyzék

1	Osztályozás	2
2	Költség függvény	3
2.1	Egyszerűsített költség függvény	5
2.2	Gradiens módszer logisztikus reggeszióhoz	5
3	Osztályozás több osztállyal	5
4	Túltanulás	6


1 Osztályozás

Egy eldöntendő kérdést próbálunk modellezni.

Pl.: $x^{(i)}$ valamilyen jellemzői egy email-nek, $y^{(i)}$ pedig pedig 1 ha spam, 0 ha nem az.


Megpróbálhatnánk lineáris regresszióval egy egyenest illeszteni az adatkörre, majd egy határértéket megadva azt feltételezni, hogy ami balra van 0 kimenet, jobbra pedig 1-et ad.

A probléma ezzel a megvalósítással az, hogy egy szélsőséges érték felboríthatja a hipotézis függvényünket, illetve $h(x)$ nem csak a $[0,1]$ intervallumon vehet fel értékeket.



A két ábra közötti különbség egyetlen plusz tanuló példa, viszont mivel így már más egyenest illeszkedik jobban az adatkörre, a zölddel bekarikázott esetekben valószínűleg rosszul fog működni az algoritmus.

Ennek kiküszöbölésére a sigmoid vagy logisztikus függvényt használhatjuk (Jele: $g(x)$), amit az alábbi kép mutat be.



$$h_{\theta}(x) = g(\theta^T x)$$

$$z = \theta^T x$$

$$g(z) = \frac{1}{1+e^{-z}}$$

A függvény értékkészlete így már a $[0,1]$ intervallumba esik, így sokkal jobban használható osztályozásra.

$h_\theta(x)$ annak az esélyét fogja visszacni, hogy az adott példának mekkora eséllyel 1 a kimenete ($P(y = 1|x; \theta)$).

$y=1$, ha $h(x) \geq 0.5$, azaz $z \geq 0$
 $y=0$, ha $h(x) < 0.5$, azaz $z < 0$

Döntési felület:

az a sík, ami elválasztja a pozitív(1) és negatív(0) példákat.

Ha nem egy egyenes a megfelelő elválasztó az y értékek között, adhatunk a $g(z)$ sigmoid függvénynek nem lineáris paramétert is, pl. ami egy kört ír le.


2 Költség függvény

A lineáris regressziónál használt költség függvény túl sok lokális minimumot adna vissza, viszont mi inkább egy konvex függvényt szeretnénk.

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m Cost(h_\theta(x^{(i)}), y^{(i)})$$

$$Cost(h_\theta(x), y) = -\log(h_\theta(x)) \quad \text{ha } y = 1$$

$$Cost(h_\theta(x), y) = -\log(1 - h_\theta(x)) \quad \text{ha } y = 0$$



Ha $y = 1$, de $h(x) \approx 0$, akkor mivel $-\log(x)$ a végtelenbe konvergál a 0 irányába, a költség függvényünk is a végtelenbe fog tartani, ezzel jelezve, hogy nagyon mellé lőtt az algoritmus. Ellenkező esetben pedig a 0-ba konvergál $-\log(x)$, azaz minél közelebb van y -hoz $h(x)$, annál kisebb lesz a költség függvény értéke, ami nekünk pont a megfelelő működést jelenti.

2.1 Egyszerűsített költség függvény

$$Cost(h_\theta(x), y) = -y \log(h_\theta(x)) - (1 - y) \log(1 - h_\theta(x))$$

Így ha $y = 0$, az első tag kiesik, ha $y = 1$ akkor pedig a második, a maradék pedig pont a fentebb említett egyenletek egyike lesz.

A teljes J költség függvényünk tehát a következő lesz:

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log(h_\theta(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_\theta(x^{(i)}))]$$

vagy vektorizálva:

$$h = g(X\theta) \\ J(\theta) = \frac{1}{m} - y^T \log(h) - (1 - y)^T \log(1 - h)$$

2.2 Gradiens módszer logisztikus reggeszióhoz

A képlet továbbra is a következő, csak a költség függvényünk változott meg

$$\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

Vektorizálva:


$$\theta := \theta - \frac{\alpha}{m} X^T (g(X\theta) - y)$$

3 Osztályozás több osztállyal

Pl. email mappákba sorolása (munka, család, spam)
 $y = 0, 1, \dots, n$

Felbontjuk a problémát $n+1$ alproblémára, mindegyiknél azt feltételezzük, hogy y az egyik osztályban van, így mindegyik alproblémában $y = 0, 1$, mert vagy tényleg abban az osztályban van vagy nem. Végül azt választjuk, aminek legnagyobb valószínűsége volt.

4 Túltanulás



A bal oldali ábrán az elsőfokú hipotézis függvényünk nem igazán illeszkedik jól a tanuló példákra, ezt alultanulásnak (underfitting) hívjuk.

A középső példához már hozzáadtunk egy saját x^2 jellemzőt, amivel láthatóan jobban illeszkedik a modellünk, így gondolhatnánk, hogy újabb jellemzők felvétele mindig pontosítja a hipotézis függvényt. Ennek cáfolata a jobb szélső példa, ahol egy ötödfokú polinom is szerepel a képletben, ezzel szinte tökéletesen illeszkedik a tanuló példáinkra, viszont szemmel láthatóan nem igazán alkalmas arra, hogy egy új példa értékét jósoljuk meg vele. Ezt hívjuk Túltanulásnak (overfitting).

A túltanulás a következő módokon orvosolható:

- Csökkentsük a jellemzők számát
 - Válasszuk ki melyikeket szeretnénk megtartani
 - Használjunk modell szelekciós algoritmust
- Regularizáció
 - Hagyjuk meg a jellemzőket, de büntessük azokat, amelyek túl nagy hatással vannak
 - A regularizáció akkor működik jól, ha sok olyan változónk van, amik csak kisebb hatással vannak a költségre

Tfh. túltanulás problémánk van és inkább négyzeteshez hasonló függvényt szeretnénk illeszteni e helyett:

$$\theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$$

Ha az akarjuk hogy kisebb hatással legyen a $\theta_3 x^3$ és $\theta_4 x + 4$ tag, módosítanunk kell a költség függvényünket:

$$\min_{\theta} \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + 1000 * \theta_3^2 + 1000 * \theta_4^2$$

Ahhoz, hogy ez a függvény minimális legyen, a θ_3 és θ_4 tagoknak közel 0-nak kell lenni.

Viszont ha túl sok jellemzőnk van, nem biztos hogy tudni fogjuk melyikiek vannak nagy hatással, ezért regularizáljuk mindet.

$$\min_{\theta} \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^n \theta_j^2$$

Ahol λ a regularizációs paraméter, ami meghatározza hogy az egyes θ paraméterek költségei mennyire arányosak.